

Homework Assignment No. 1

Binary Choice Models –

Application to electric-vehicle adoption

Alumno: Alan Wilson Germany

Profesor: Sebastián Astroza

Fecha: 25/04/2025

1. Examine Characteristics of Data Set (15 pts)

- La mayoría de los hogares no adoptan vehículos eléctricos, con una proporción que más que triplica a los que sí lo hacen (77,2% vs. 22,8%) (**Anexo 1**). Esto podría deberse a diversos motivos, para lo cual analizaremos diferentes aspectos que podrían influir en la decisión de si adoptar o no.

Respecto a la distribución de las variables, no se encontró nada extraño, a excepción de la variable “**DIST**”, el resto de las variables tienen distribuciones normales y siguen una tendencia clara

- En cuanto al ingreso, se observa una leve mayor proporción de adopción en los niveles altos de “**INCOME**”, aunque sin un patrón claro o determinante. Esto sugiere que el ingreso, por sí solo, no explica la decisión de adopción, dejando espacio para considerar factores como culturales o actitudes (**Anexo 2**).
- La presencia de paneles solares en el hogar (“**SOLPAN**”) muestra una diferencia más notoria. Los hogares con paneles tienen una tasa de adopción significativamente más alta, lo que podría reflejar una mayor conciencia ambiental o afinidad con tecnologías sustentables (**Anexo 3**).
- Cuando los vecinos tienen vehículos eléctricos (“**NEIGHB**”), la tasa de adopción sube, en comparación a cuando no los tienen, supuesto esperado (**Anexo 4**).
- Al observar la estructura familiar, se nota que los hogares más pequeños tienden a adoptar con mayor frecuencia. Además, hay una mayor proporción de mujeres y una menor de hombres en los hogares adoptantes (**Anexo 5**).
- El uso de transporte público (“**PTRANSP**”) también se relaciona positivamente con la adopción. Los hogares que lo utilizan presentan una tasa de adopción más alta. Lo mismo ocurre con quienes teletrabajan (“**TELECO**”), quienes podrían tener mayor familiaridad con herramientas digitales y mayor capacidad de inversión en tecnologías nuevas (**Anexo 6**).

2. Estimate Base Market Share Model (10 pts)

Para este problema, se estimó la constante para la alternativa "adopt" (adoptar un vehículo eléctrico), mientras que la constante de "notadopt" fue fijada en cero como referencia.

El resultado estimado fue:

- **Constante asc_adopt = -1.221** (error estándar robusto: 0.0472, t-ratio: -25.85)

Los datos de este output están en el **Anexo 7**.

Este coeficiente es estadísticamente significativo y su signo negativo indica que, en ausencia de cualquier otra variable explicativa, la alternativa "adopt" tiene una utilidad sistémica menor que "notadopt". Es decir, el modelo predice que, por defecto, los hogares tienen una mayor inclinación a no adoptar la tecnología.

Esta estimación se relaciona directamente con los resultados de la Pregunta 1, donde se observó que solo 22,8% de los hogares adopta. El signo y magnitud de la constante reflejan este desbalance: una constante negativa implica que la probabilidad de adopción es baja en el modelo, coherente con lo observado empíricamente en los datos.

La relación entre la constante y la participación de mercado se puede entender también a partir de la fórmula del modelo logit simple con constantes, el modelo fue visto en clases, la formula a continuación está adaptada para el caso actual:

$$P(adopt) = \frac{e^{asc_{adopt}}}{e^{asc_{adopt}} + e^{asc_{notadopt}}}$$

Dado que "asc_notadopt" = 0, la fórmula queda:

$$P(adopt) = \frac{e^{-1.221}}{e^{-1.221} + 1} \approx 0.228$$

Este valor es prácticamente idéntico al 22,8% observado en los datos, lo que confirma que el modelo base representa adecuadamente el comportamiento real de los hogares frente a la adopción.

El resultado indica que el modelo base estima correctamente las proporciones de adopción observadas, y el signo negativo de la constante para "adopt" refleja una menor predisposición a esa alternativa en ausencia de otras variables.

3. Estimate Binary Choice Model with Explanatory Variables (10pts)

a) Las variables consideradas fueron "SPOOL", "GRAD", "PTRANSP", "PSENIORS", "NCHILD" y "COST".

Los resultados (*Anexo 8*) muestran que:

- **asc_adopt = -0.951**, estadísticamente significativo ($t = -5.17$). Se mantiene el efecto base negativo para adoptar, aunque menor en magnitud respecto al modelo sin variables (pregunta 2), indicando que parte de la utilidad se explica ahora por los regresores.
- **b_ptransp = 0.289**, significativo ($t = 2.76$): los hogares que usan transporte público tienen mayor probabilidad de adoptar un vehículo eléctrico, lo cual tiene sentido intuitivo al estar alineado la idea de nuevas formas de transporte.
- **b_cost = -0.048**, marginalmente significativo ($t = -1.80$): el signo negativo es coherente, ya que un mayor costo desincentiva la adopción. Aunque el efecto no es altamente significativo.
- **b_spool, b_grad, b_pseniors y b_nchild** no resultaron significativos ($t < |1.5|$). A pesar de no ser estadísticamente concluyentes, sus signos son razonables, era algo esperable:

- **b_pseniors** negativo: hogares con adultos mayores podrían mostrar menor disposición al cambio tecnológico.
- **b_grad** positivo: mayor educación podría asociarse con mayor probabilidad de adopción, aunque el efecto fue débil.
- **b_spool** y **b_nchild** muestran coeficientes cercanos a cero, sugiriendo que no aportan variabilidad explicativa relevante en este modelo.

Estos resultados permiten concluir que al menos dos variables explicativas aportan significativamente al modelo: el uso de transporte público ("PTRANSP") y el costo del vehículo ("COST"). Ambas muestran signos consistentes con la teoría y la intuición, mientras que el resto no alcanza significancia estadística, aunque algunas variables entregan señales coherentes que podrían explorarse en otras pruebas del modelo.

b) Se realizó una reestimación del modelo (**Anexo 9**), eliminando aquellas variables que no eran estadísticamente significativas ($|t| < 1.00$), en este caso fueron **"SPOOL"**, **"GRAD"** y **"NCHILD"**, luego añadiendo dos términos de interacción: $COST * Medium_income$ y $COST * High_income$, donde $Medium_income$ y $High_income$ son variables dummy que representan niveles de ingreso medio y alto respectivamente.

El modelo sin las interacciones (Pregunta 3.a) obtuvo un log-verosimilitud final de **-1362.02**, mientras que el modelo con interacciones alcanzó un $LL(\text{final})$ de **-1358.06**. Se aplicó un **Likelihood Ratio Test (LRT)**, obteniendo un valor de **7.92**.

$$LRT = -2 \times (LL(3.A) - LL(3.B))$$

Dado que este valor supera el umbral crítico de 5.99 para 2 grados de libertad (al 95% de confianza), se concluye que la inclusión de las interacciones mejora significativamente el ajuste del modelo. Esto indica que el impacto del costo sobre la adopción de vehículos eléctricos varía según el nivel de ingreso del hogar, y que capturar esta heterogeneidad mejora la capacidad explicativa del modelo.

4. Searching for Your Final Specification (15 pts)

a) Para este modelo, se incorporaron variables relevantes identificadas en los análisis previos (preguntas 1 y 3), combinadas con decisiones tomadas a partir de la intuición y del razonamiento sobre factores que podrían influir en la adopción de un vehículo eléctrico. Con el objetivo de reflejar mejor la diversidad entre los hogares y capturar relaciones no lineales, algunas variables continuas fueron transformadas en categorías discretas. Asimismo, se construyeron interacciones relevantes para estudiar efectos conjuntos entre dimensiones como la distancia y el uso del transporte público (ver Anexos 10 y 11).

Variables continuas transformadas en categorías (dummies):

- **"POPDENSE"** fue dividida en **"POPD_BAJO"**, **"POPD_MEDIA"** y **"POPD_ALTO"**, bajo la hipótesis de que las condiciones de transporte y movilidad varían según la densidad del entorno.
- **"DIST"** se segmentó en **"DIST_CORTA"**, **"DIST_MEDIA"** y **"DIST_LARGA"**, considerando que la necesidad de un vehículo puede cambiar dependiendo del tramo de distancia. Estas categorías luego se utilizaron en interacciones específicas con el transporte público.
- **"HHSIZE"** fue dividida en **"HOGAR_PEQUEÑO"**, **"HOGAR_MEDIANO"** y **"HOGAR_GRANDE"**, para representar diferencias en la estructura del hogar y sus necesidades de movilidad.
- **"COST"** se convirtió en dummies **"COST_BAJO"**, **"COST_MEDIO"** (referencia) y **"COST_ALTO"**, con el fin de modelar la sensibilidad al precio de forma más flexible.

También se incorporaron nuevas variables categóricas de ingreso: **"Medium_income"** y **"High_income"**, las cuales representan distintos niveles de ingreso de los hogares.

En todos los casos, se excluyó una categoría como base para evitar colinealidad: **"POPD_BAJO"**, **"DIST_CORTA"**, **"HOGAR_GRANDE"** y **"COST_MEDIO"**.

Interacciones creadas: Se incluyeron las variables **"PTRANSP_MEDIA"** y **"PTRANSP_LARGA"**, generadas al interactuar **"PTRANSP"** (uso de transporte público) con **"DIST_MEDIA"** y **"DIST_LARGA"**, respectivamente. Esto permitió capturar cómo el contexto geográfico modifica el impacto del transporte público sobre la decisión de adopción.

Resultados del modelo final (Anexo 12):

- **LL(final)** = -1349.62: el valor más alto obtenido hasta ahora (menos negativo), indicando el mejor ajuste sobre los datos.
- **Rho² (vs equal shares)** = 0.2364: el modelo logra explicar aproximadamente un 23.6% de la variabilidad en la decisión de adopción.
- **AIC = 2723.25** y **BIC = 2793.37**: ambos menores que en versiones previas, sugiriendo un mejor balance entre ajuste y complejidad.

Principales hallazgos del modelo:

- **"SOLPAN"** fue significativa y positiva (**coef. = 0.464**), lo que indica que los hogares con paneles solares son más propensos a adoptar vehículos eléctricos, probablemente por una mayor afinidad con tecnologías sustentables.
- **"PTRANSP_MEDIA"** (**coef. = 0.261**) resultó significativa, sugiriendo que, en zonas a distancia media, el transporte público complementa positivamente la decisión de adopción.
- **"POPD_ALTO"** (**coef. = -0.316**) fue negativa y significativa, lo que indica que, en áreas de alta densidad, donde suele haber mayor acceso a transporte público tradicional, la necesidad de un vehículo eléctrico es menor.

- **"COST_BAJO"** (coef. = **-0.0098**) no fue significativo, lo cual sugiere que en esta muestra, los hogares no reaccionan de manera clara ante precios bajos respecto al costo medio. Una posible interpretación es que precios bajos podrían generar desconfianza o percepción de menor calidad.
- **"COST_ALTO"** (coef. = **-0.219**) fue negativo y marginalmente significativo, indicando que enfrentar un costo alto disminuye la utilidad relativa y reduce la probabilidad de adopción.
- **"PTRANSP_LARGA"** (coef. = **0.359**) fue significativa, mostrando que en zonas más alejadas, el transporte público continúa teniendo un impacto relevante.
- Otras variables como **"NEIGHB"** y **"HOGAR_PEQUEÑO"** mostraron signos coherentes (positivos), aunque con significancia moderada. Se esperaba una mayor relevancia de **"NEIGHB"**, ya que por lógica social se podría anticipar que la presencia de vehículos eléctricos en el entorno influye positivamente en la decisión de adopción.

b) En la especificación final, se utilizó la variable **"COST"** como continua para evaluar directamente su efecto marginal sobre la utilidad asociada a la adopción de vehículos eléctricos. El coeficiente estimado fue de **-0.0506 (Anexo 13)**, lo que implica que, por cada unidad adicional en el valor del costo, la utilidad relativa de elegir un vehículo eléctrico disminuye en aproximadamente 0.0506 unidades. Esta interpretación es coherente con la expectativa de que, a mayor costo, menor atractivo percibido por parte del consumidor.

El signo negativo del coeficiente confirma que el costo funciona como una barrera, desincentivando la adopción. Su magnitud, en torno a **-0.0506**, indica que por cada unidad adicional de costo, la utilidad disminuye ligeramente. Esto sugiere que el precio tiene un efecto real sobre la decisión, pero no lo suficientemente fuerte como para ser el factor principal. En otras palabras, el costo influye, pero no domina la

elección. Desde el punto de vista estadístico, el t-ratio cercano a -1.88 refleja una significancia marginal: hay evidencia de que el efecto existe, aunque no con total certeza.

Este resultado también se alinea con lo observado en el modelo alternativo con costo categorizado (4.a), donde **"COST_ALTO"** tuvo un coeficiente negativo y marginalmente significativo (**-0.219**), mientras que **"COST_BAJO"** no resultó estadísticamente relevante. Ambos enfoques coinciden en que enfrentar un costo alto reduce la utilidad, aunque la magnitud del efecto varía según cómo se modele el precio.

Usar el costo como una variable continua ayuda a entender mejor cómo influye el precio en la decisión de adoptar un vehículo eléctrico. Esta forma de modelarlo muestra que, aunque el precio sí importa, no es el único elemento en juego. De hecho, factores como el nivel de ingreso, la conciencia ambiental o el lugar donde vive la persona podrían tener incluso más peso en esa elección.

Estos resultados respaldan la idea de aplicar políticas públicas que reduzcan el precio de los vehículos eléctricos, como subsidios o beneficios tributarios. Sin embargo, dado que el efecto del costo no es tan grande por sí solo, esas políticas probablemente funcionen mejor si van acompañadas de otras medidas, como mejorar la infraestructura de carga o aumentar la confianza de las personas en esta tecnología.

5. Aggregate Effect on Adoption shares Due to Level-of-Service Changes (10 pts)

Se utilizó el modelo final estimado (con el costo como variable continua y las variables de ingreso incorporadas) para evaluar el impacto de una política de reducción del costo de los vehículos eléctricos en un 25%.

Primero, se calcularon las predicciones de adopción bajo el escenario actual, es decir, con los precios originales. El modelo predijo una tasa promedio de adopción **de 22.78% (Anexo 14)**, lo cual está alineado con la proporción observada en los datos (Anexo correspondiente).

Posteriormente, se simuló una reducción del 25% en el costo (“**COST**”) de los vehículos eléctricos, manteniendo constantes todas las demás variables. Bajo este nuevo escenario, la tasa promedio de adopción aumentó a **24.19% (Anexo 14)**.

Además, se calculó la elasticidad aproximada de adopción respecto al costo, obteniéndose un valor de **-0.207**. Este valor implica que una reducción del costo genera un aumento moderado en la adopción: específicamente, una disminución de 1% en el costo incrementaría la adopción en aproximadamente 0.207%.

En conjunto, estos resultados sugieren que la política de reducción de costos tendría un efecto positivo en estimular la adopción de vehículos eléctricos. Sin embargo, dado que el impacto estimado es moderado, sería recomendable que este tipo de medidas se complementen con estrategias adicionales, como subsidios, incentivos fiscales, fortalecimiento de la infraestructura de carga, y campañas de promoción que aborden otras barreras que afectan la decisión de los hogares.

Anexos

```
print(df['CHOSEN'].value_counts(normalize=True) * 100)
```


✓ 0.0s

CHOSEN


2	77.215686
1	22.784314

Name: proportion, dtype: float64


Anexo 1: Distribución general de adopción de vehículos eléctricos (77.2% vs 22.8%)




Anexo 2: Ingreso y su relación con adopción de vehículos eléctricos




Anexo 3: Impacto de la presencia de paneles solares (“SOLPAN”) en adopción



Anexo 4: Influencia de vecinos con vehículos eléctricos (“NEIGHB”)



Anexo 5: Tamaño del hogar, género y su efecto en adopción



Anexo 6: Transporte público (“PTRANSP”) y teletrabajo (“TELECO”) versus adopción

```

LL(start) : -1767.53
LL at equal shares, LL(0) : -1767.53
LL at observed shares, LL(C) : -1368.48
LL(final) : -1368.48
Rho-squared vs equal shares : 0.2258
Adj.Rho-squared vs equal shares : 0.2252
Rho-squared vs observed shares : 0
Adj.Rho-squared vs observed shares : 0
AIC : 2738.95
BIC : 2744.79

Estimated parameters : 1
Time taken (hh:mm:ss) : 00:00:0.27
  pre-estimation : 00:00:0.16
  estimation : 00:00:0.09
  post-estimation : 00:00:0.03
Iterations : 7

Unconstrained optimisation.

Estimates:

```

	Estimate	s.e.	t.rat.(0)	Rob.s.e.	Rob.t.rat.(0)
asc_adopt	-1.221	0.04721	-25.85	0.04722	-25.85
asc_notadopt	0.000	NA	NA	NA	NA

Anexo 7: Estimación del modelo base (solo constantes)

```

LL(start) : -1767.53
LL at equal shares, LL(0) : -1767.53
LL at observed shares, LL(C) : -1368.48
LL(final) : -1362.02
Rho-squared vs equal shares : 0.2294
Adj.Rho-squared vs equal shares : 0.2255
Rho-squared vs observed shares : 0.0047
Adj.Rho-squared vs observed shares : 3e-04
AIC : 2738.04
BIC : 2778.94

Estimated parameters : 7
Time taken (hh:mm:ss) : 00:00:0.66
  pre-estimation : 00:00:0.35
  estimation : 00:00:0.11
  post-estimation : 00:00:0.2
Iterations : 6

Unconstrained optimisation.

Estimates:

```

	Estimate	s.e.	t.rat.(0)	Rob.s.e.	Rob.t.rat.(0)
asc_notadopt	0.00000	NA	NA	NA	NA
asc_adopt	-0.95094	0.18597	-5.1134	0.18384	-5.1725
b_spool	-0.04413	0.10923	-0.4040	0.10896	-0.4051
b_grad	0.04011	0.07564	0.5303	0.07524	0.5331
b_ptransp	0.28891	0.10472	2.7587	0.10477	2.7575
b_pseniors	-0.17783	0.13952	-1.2746	0.14040	-1.2666
b_nchild	-0.01748	0.04239	-0.4125	0.04079	-0.4286
b_cost	-0.04804	0.02698	-1.7807	0.02663	-1.8038

Anexo 8: Resultados del primer modelo con variables explicativas ("SPOOL", etc.)

```

LL(start) : -1767.53
LL at equal shares, LL(0) : -1767.53
LL at observed shares, LL(C) : -1368.48
LL(final) : -1358.06
Rho-squared vs equal shares : 0.2317
Adj.Rho-squared vs equal shares : 0.2288
Rho-squared vs observed shares : 0.0076
Adj.Rho-squared vs observed shares : 0.0047
AIC : 2726.11
BIC : 2755.33

Estimated parameters : 5
Time taken (hh:mm:ss) : 00:00:0.43
    pre-estimation : 00:00:0.23
    estimation : 00:00:0.1
    post-estimation : 00:00:0.1
Iterations : 7

Unconstrained optimisation.

Estimates:

```

	Estimate	s.e.	t.rat.(0)	Rob.s.e.	Rob.t.rat.(0)
asc_notadopt	0.00000	NA	NA	NA	NA
asc_adopt	-1.45922	0.08242	-17.704	0.08165	-17.872
b_ptransp	0.29795	0.10493	2.839	0.10470	2.846
b_pseniors	-0.18122	0.13577	-1.335	0.13647	-1.328
b_cost_medINC	0.04359	0.01524	2.860	0.01489	2.928
b_cost_altoINC	0.05330	0.01871	2.849	0.01842	2.894

Anexo 9: Comparación de log-verosimilitud entre modelo inicial y modelo con interacciones.

```

q33_pop = df['POPDENSE'].quantile(0.33)
q66_pop = df['POPDENSE'].quantile(0.66)

df['POPD_BAJO'] = (df['POPDENSE'] <= q33_pop).astype(int)
df['POPD_MEDIA'] = ((df['POPDENSE'] > q33_pop) & (df['POPDENSE'] <= q66_pop)).astype(int)
df['POPD_ALTO'] = (df['POPDENSE'] > q66_pop).astype(int)

q33_dist = df['DIST'].quantile(0.33)
q66_dist = df['DIST'].quantile(0.66)

df['DIST_CORTA'] = (df['DIST'] <= q33_dist).astype(int)
df['DIST_MEDIA'] = ((df['DIST'] > q33_dist) & (df['DIST'] <= q66_dist)).astype(int)
df['DIST_LARGA'] = (df['DIST'] > q66_dist).astype(int)

df['HOGAR_PEQUEÑO'] = (df['HHSIZE'] <= 2).astype(int)
df['HOGAR_MEDIANO'] = ((df['HHSIZE'] > 2) & (df['HHSIZE'] <= 4)).astype(int)
df['HOGAR_GRANDE'] = (df['HHSIZE'] > 4).astype(int)

```

Anexo 10: Variables categorizadas (transformación de "POPDENSE", "DIST", "HHSIZE")

```
df['PTRANSP_CORTA'] = df['PTRANSP'] * df['DIST_CORTA']
df['PTRANSP_MEDIA'] = df['PTRANSP'] * df['DIST_MEDIA']
df['PTRANSP_LARGA'] = df['PTRANSP'] * df['DIST_LARGA']
```

Anexo 11: Interacciones creadas ("PTRANSP_MEDIA" y "PTRANSP_LARGA")

LL(start)	:	-1767.53			
LL at equal shares, LL(0)	:	-1767.53			
LL at observed shares, LL(C)	:	-1368.48			
LL(final)	:	-1340.18			
Rho-squared vs equal shares	:	0.2418			
Adj.Rho-squared vs equal shares	:	0.2339			
Rho-squared vs observed shares	:	0.0207			
Adj.Rho-squared vs observed shares	:	0.0112			
AIC	:	2708.35			
BIC	:	2790.16			
Estimated parameters	:	14			
Time taken (hh:mm:ss)	:	00:00:0.99			
pre-estimation	:	00:00:0.38			
estimation	:	00:00:0.12			
post-estimation	:	00:00:0.5			
Iterations	:	7			
Unconstrained optimisation.					
Estimates:					
	Estimate	s.e.	t.rat.(0)	Rob.s.e.	Rob.t.rat.(0)
asc_notadopt	0.000000	NA	NA	NA	NA
asc_adopt	-1.670462	0.2024	-8.25193	0.2059	-8.11367
b_NEIGHB	0.166271	0.1150	1.44558	0.1148	1.44793
b_SOLPAN	0.463893	0.1714	2.70711	0.1710	2.71336
b_Medium_income	0.410357	0.1086	3.77826	0.1087	3.77488
b_High_income	0.463334	0.1307	3.54526	0.1306	3.54800
b_POPD_MEDIA	-0.147227	0.1153	-1.27704	0.1155	-1.27451
b_POPD_ALTO	-0.316376	0.1179	-2.68350	0.1180	-2.68161
b_HOGAR_MEDIANO	0.462132	0.1776	2.60241	0.1784	2.59036
b_HOGAR_PEQUEÑO	0.262660	0.1754	1.49720	0.1759	1.49356
b_ptransp_media	0.261061	0.1673	1.56009	0.1657	1.57588
b_ptransp_larga	0.358519	0.1515	2.36678	0.1522	2.35523
b_cost_bajo	-0.009834	0.1156	-0.08510	0.1157	-0.08499
b_cost_alto	-0.218728	0.1182	-1.85035	0.1177	-1.85788
b_pseniors	-0.185366	0.1435	-1.29189	0.1440	-1.28756

Anexo 12: Resultados del modelo final con 14 parámetros estimados.

LL(start)	:	-1767.53			
LL at equal shares, LL(0)	:	-1767.53			
LL at observed shares, LL(C)	:	-1368.48			
LL(final)	:	-1340.63			
Rho-squared vs equal shares	:	0.2415			
Adj.Rho-squared vs equal shares	:	0.2342			
Rho-squared vs observed shares	:	0.0203			
Adj.Rho-squared vs observed shares	:	0.0116			
AIC	:	2707.27			
BIC	:	2783.24			
Estimated parameters	:	13			
Time taken (hh:mm:ss)	:	00:00:0.84			
pre-estimation	:	00:00:0.32			
estimation	:	00:00:0.17			
post-estimation	:	00:00:0.35			
Iterations	:	7			
Unconstrained optimisation.					
Estimates:					
	Estimate	s.e.	t.rat.(0)	Rob.s.e.	Rob.t.rat.(0)
asc_notadopt	0.00000	NA	NA	NA	NA
asc_adopt	-1.42456	0.26063	-5.466	0.25673	-5.549
b_NEIGHB	0.16881	0.11497	1.468	0.11481	1.470
b_SOLPAN	0.45533	0.17117	2.660	0.17087	2.665
b_Medium_income	0.40830	0.10858	3.760	0.10880	3.753
b_High_income	0.46396	0.13066	3.551	0.13055	3.554
b_POPD_MEDIA	-0.14640	0.11526	-1.270	0.11550	-1.268
b_POPD_ALTO	-0.31849	0.11783	-2.703	0.11797	-2.700
b_HOGAR_MEDIANO	0.46357	0.17757	2.611	0.17837	2.599
b_HOGAR_PEQUEÑO	0.26375	0.17538	1.504	0.17581	1.500
b_ptransp_media	0.25949	0.16730	1.551	0.16547	1.568
b_ptransp_larga	0.36243	0.15140	2.394	0.15221	2.381
b_pseniors	-0.18820	0.14336	-1.313	0.14372	-1.310
b_cost	-0.05055	0.02725	-1.855	0.02683	-1.884

Anexo 13: Resultados del modelo alternativo con “COST” como variable continua

> ### Look at a summary of the predicted choice probabilities					
> summary(predictions_base)					
ID	Observation	notadopt	adopt	chosen	
Min. : 1.0	Min. :1	Min. :0.4822	Min. :0.0863	Min. :0.09596	
1st Qu.: 638.2	1st Qu.:1	1st Qu.:0.7341	1st Qu.:0.1831	1st Qu.:0.64913	
Median :1275.5	Median :1	Median :0.7793	Median :0.2207	Median :0.75897	
Mean :1275.5	Mean :1	Mean :0.7722	Mean :0.2278	Mean :0.65588	
3rd Qu.:1912.8	3rd Qu.:1	3rd Qu.:0.8169	3rd Qu.:0.2659	3rd Qu.:0.80992	
Max. :2550.0	Max. :1	Max. :0.9137	Max. :0.5178	Max. :0.91370	
> ### Look at a summary of the predicted choice probabilities					
> summary(predictions_new)					
ID	Observation	notadopt	adopt	chosen	
Min. : 1.0	Min. :1	Min. :0.4701	Min. :0.09513	Min. :0.1029	
1st Qu.: 638.2	1st Qu.:1	1st Qu.:0.7181	1st Qu.:0.19595	1st Qu.:0.6302	
Median :1275.5	Median :1	Median :0.7646	Median :0.23537	Median :0.7439	
Mean :1275.5	Mean :1	Mean :0.7581	Mean :0.24186	Mean :0.6485	
3rd Qu.:1912.8	3rd Qu.:1	3rd Qu.:0.8040	3rd Qu.:0.28191	3rd Qu.:0.7966	
Max. :2550.0	Max. :1	Max. :0.9049	Max. :0.52987	Max. :0.9049	

Anexo 14: Simulación de reducción del costo y predicción de nuevas tasas de adopción.

Link con carpeta con todos los archivos:

<https://drive.google.com/drive/folders/1d4VdoFeTWWx3W1UYWHIhVoxB5BflnrGt?usp=sharing>